



Detección de Enfermedades Torácicas con IA

Documentación de Proyecto de Salud Digital

Contexto y Motivación Clínica



Impacto de la IA

La integración de algoritmos de visión artificial permite analizar volúmenes masivos de datos para detectar patrones que escapan al ojo humano, facilitando diagnósticos tempranos en patologías críticas.



Limitación Tradicional

Los modelos genéricos carecen de la precisión necesaria para distinguir entre tipos de neumonía. La optimización específica es vital para garantizar la interpretabilidad y aplicación clínica directa.

El Dataset: Fusión y Estructura

1. COVID-19 Radiography Database

Fuente masiva de Tawsifur Rahman. Proporciona una base sólida para la detección de COVID-19 mediante imágenes de tórax de alta resolución.

Origen: Kaggle / Tawsifur Rahman


2. Chest X-Ray Images

Especializado en Neumonía (Paul Mooney). Crucial para robustecer la variabilidad clínica y distinguir entre neumonía viral y bacteriana.

Origen: Kaggle / Paul Mooney

Clases Finales del Modelo:

Pneumonia Bacteriana, Viral, COVID-19 y Casos Sanos (Healthy).



Preprocesamiento y Auditoría



Limpieza

Eliminación de archivos corruptos y cachés del sistema (thumbs.db).

Integridad garantizada.



RGB Focus

Conversión forzada a espacio de color RGB.

Compatibilidad total con redes neuronales.



Resize

Redimensión a 224x224 píxeles vía **LANCZOS**.

Máxima nitidez visual.



Exportación

Guardado en JPEG (95%).

Equilibrio óptimo: peso/detalle.


Arquitectura del Modelo

Base: MobileNetV2

Elegida por su alta eficiencia y bajo costo computacional, pre-entrenada con ImageNet.

Cabeza Personalizada

- GlobalAveragePooling2D
- Capa Densa de 128 neuronas (ReLU)
- **Dropout (0.5):** Prevención agresiva de sobreajuste.
- Salida Softmax (4 clases)



Estrategia de Optimización Avanzada



Más allá de Teachable Machines

Desarrollo nativo en **TensorFlow** para un control total del entrenamiento y la arquitectura.

Balanceo y Aumento de Datos



Corrección de Desbalance

Implementación de `class_weight='balanced'` para asignar mayor importancia a las patologías menos representadas en el dataset original.



Augmentation Dinámico

Robustecimiento mediante ImageDataGenerator:

- Rotaciones aleatorias (10°)
- Zonas de Zoom (0.1)
- Desplazamientos Horizontales/Verticales
- Alteración lumínica (90% - 110%)

Fase 1: Feature Extraction



Configuración de Inicio

En esta etapa, la base de MobileNetV2 permanece **congelada** (trainable = False). Se entrena únicamente el clasificador superior.

⚙️ **Optimizador:** Adam (LR = 0.001)

🔔 **Callbacks:** EarlyStopping con paciencia de 2.

Fase 2: Fine-Tuning de Precisión

Estrategia de Descongelamiento

Se descongelan las últimas **20 capas** del modelo base para realizar ajustes sutiles al dominio médico.



Evita el "Olvido Catastrófico".



Micro-ajustes en bordes clínicos.

Parámetros de Fine-Tuning

Optimización iterativa con control de convergencia para máxima precisión.



15 épocas de entrenamiento.



EarlyStopping: Paciencia de 4.



Learning Rate = 10^{-5}

Resultados de Evaluación Auditada

Precisión (COVID-19)

96%



Recall (Bacterial)

92%



F1-Score (Normal)

98%

Resultados obtenidos mediante Reporte de Clasificación y Matriz de Confusión térmica.

Integración y Despliegue Web



Aplicación Streamlit

El modelo final se empaquetó en una interfaz web reactiva para uso clínico inmediato:

 Barra de confianza porcentual.

 **Umbral de Seguridad:** Advertencias predictivas si la certeza es inferior al 60%.

 Visualización de diagnósticos en tiempo real.